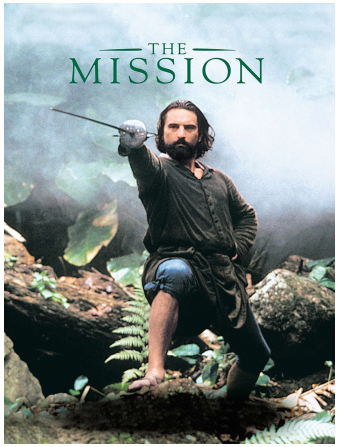
MACHINE LEARNING 2

Ciência de Dados para Negócios

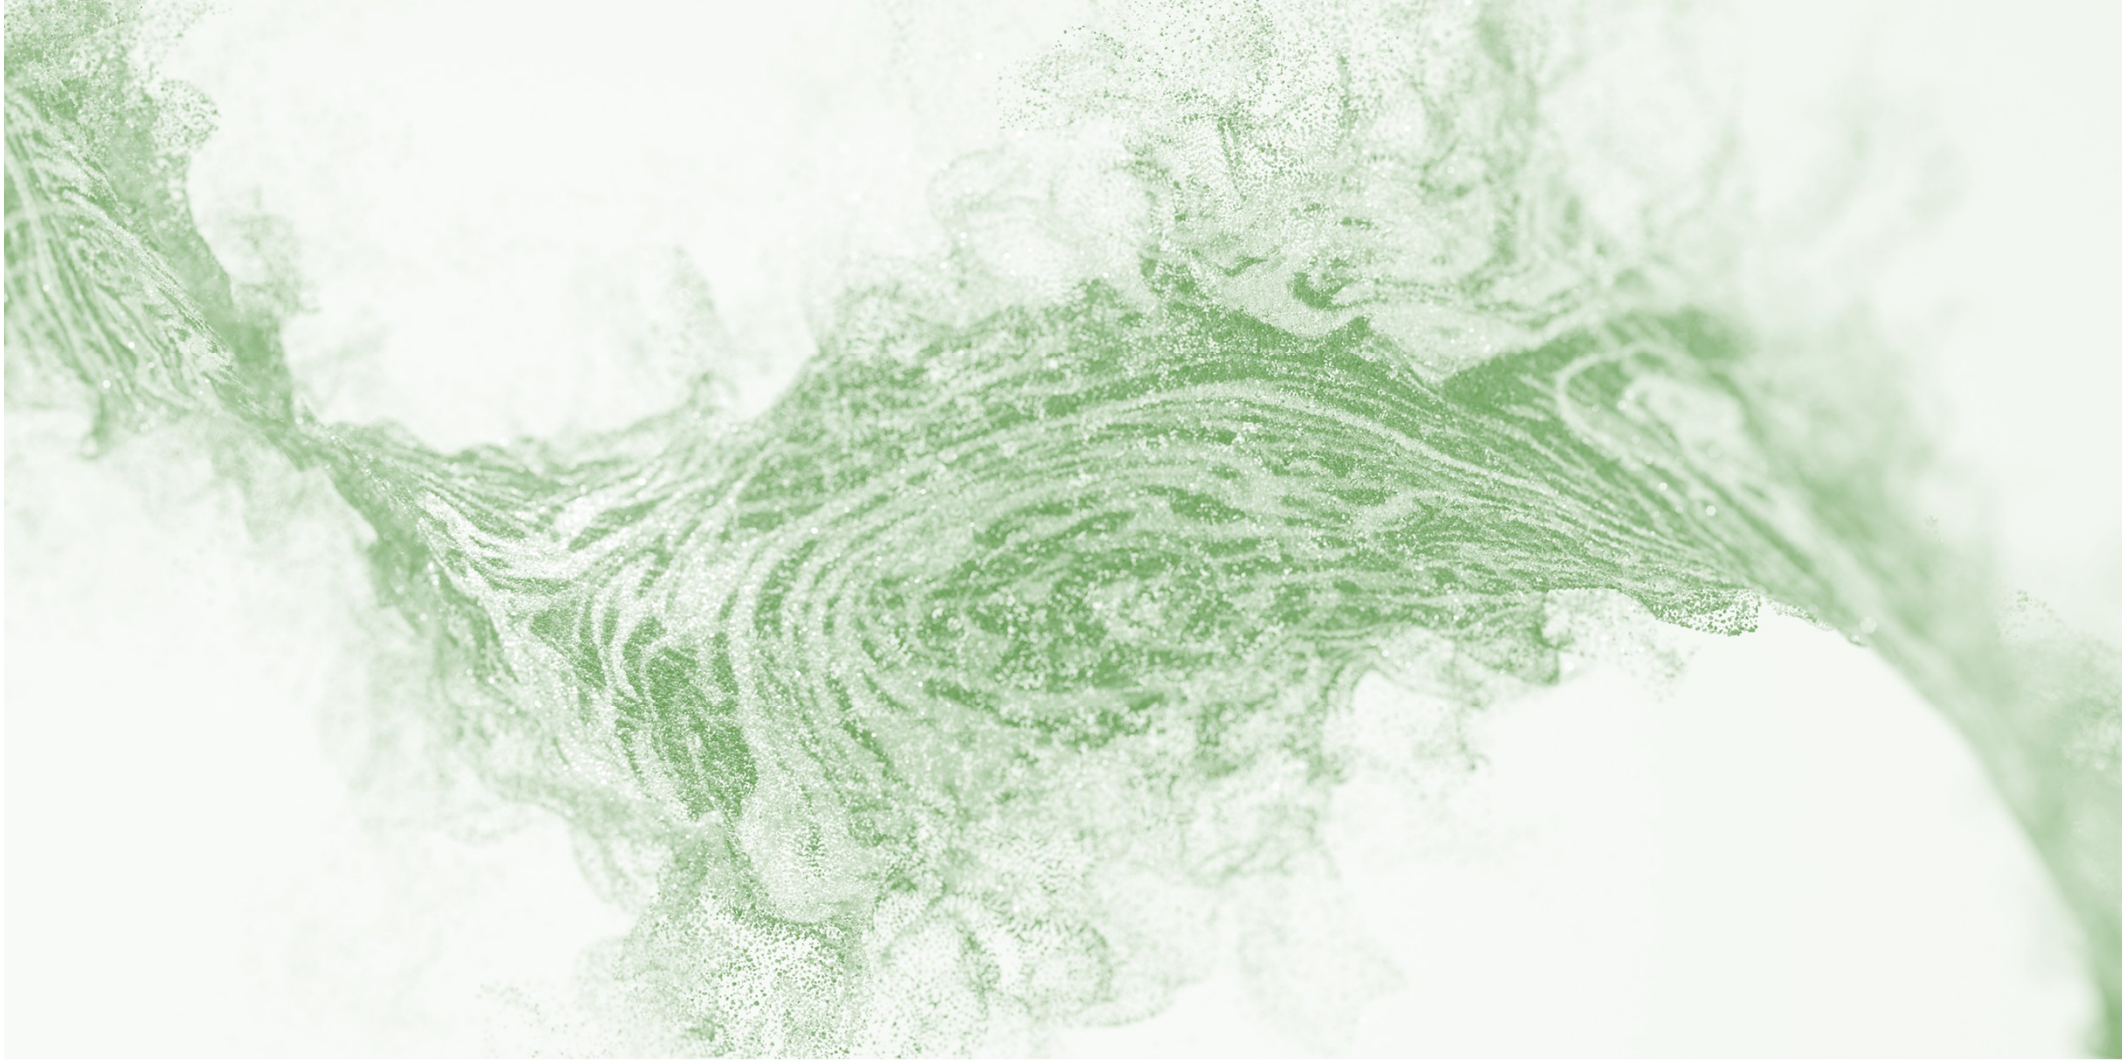
FATEC Votorantim



Prof. Luis Claudio

M. Sc. Eng. Elétrica(PUC-Rio-06)

Eng. de Computação (ITA-99)



I – INTRODUÇÃO ÀS REDES NEURAIS ARTIFICIAIS

Prof. Luis Claudio

M.Sc. Eng. Elétrica(PUC-Rio-06)

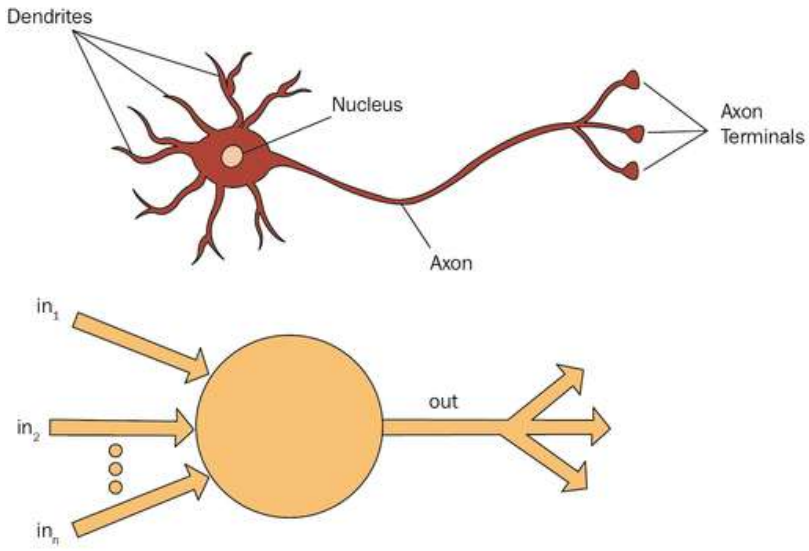
Eng. de Computação (ITA-99)

O QUE É UMA REDE NEURAL

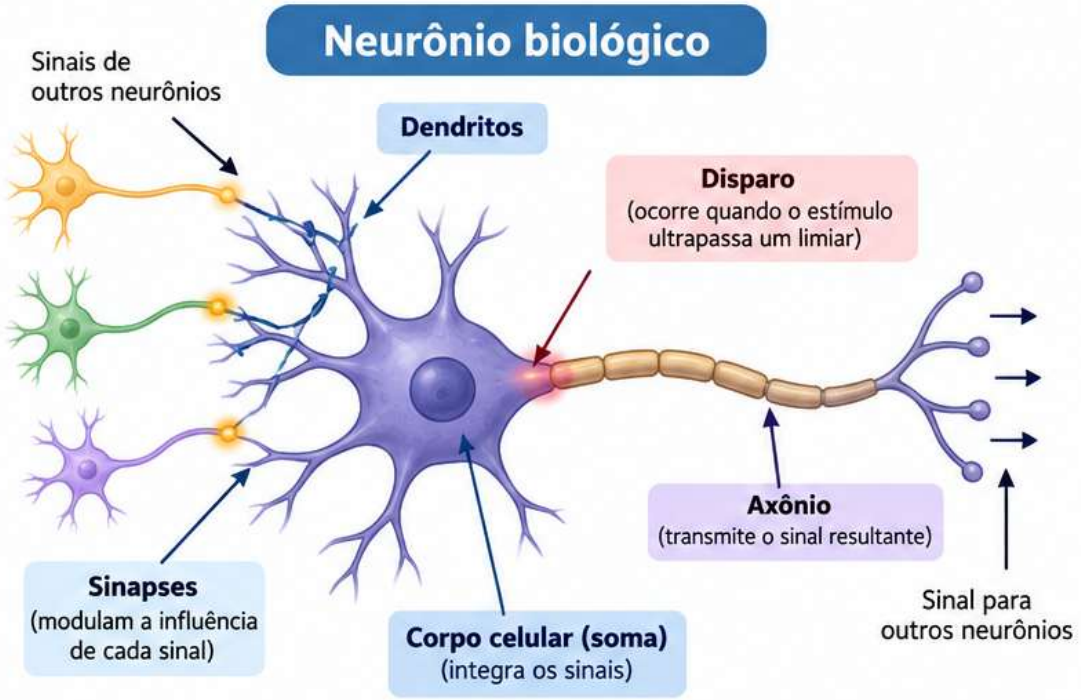
Na década de 1940, pesquisadores como **Warren McCulloch** e **Walter Pitts** tentaram responder à seguinte pergunta:

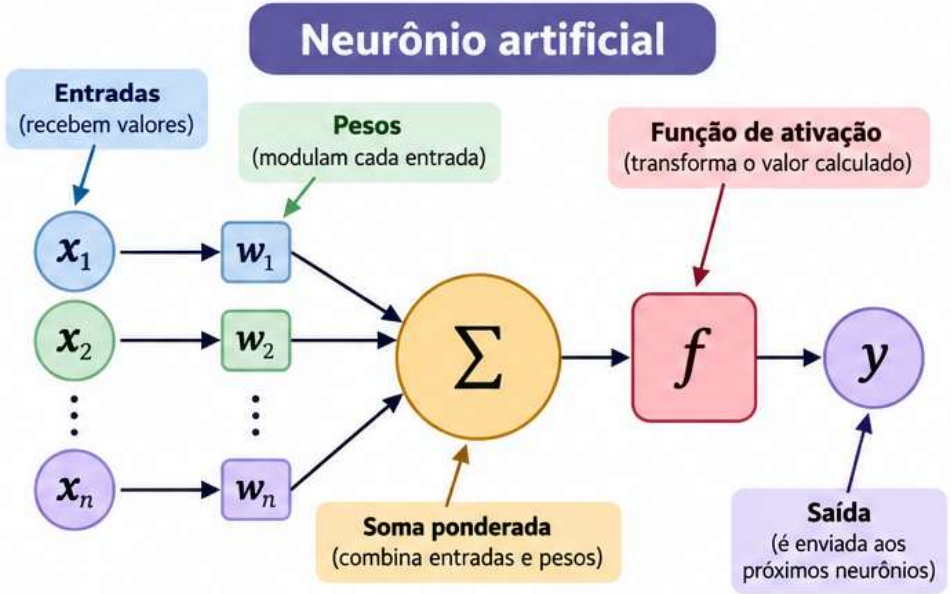
Como o cérebro consegue aprender e processar informações a partir de bilhões de neurônios interconectados?

A ideia foi criar um modelo matemático simplificado do neurônio biológico:



Neurônio biológico	Neurônio artificial
Dendritos recebem sinais de outros neurônios	**Entradas** $(x_1, x_2, \ldots, x_n)$ recebem valores
Sinapses modulam a influência de cada sinal	**Pesos** $(w_1, w_2, \ldots, w_n)$ modulam cada entrada
Corpo celular (soma) integra os sinais	**Soma ponderada** combina entradas e pesos
Disparo ocorre quando o estímulo ultrapassa um limiar	**Função de ativação** transforma o valor calculado
Axônio transmite o sinal resultante	**Saída** (y) é enviada aos próximos neurônios





$$z = \sum_{i=1}^{n} w_i x_i + b \quad \rightarrow \quad y = f(z)$$

NEURÔNIO ARTIFICIAL

O neurônio artificial é a **unidade básica de processamento** de uma rede neural. Ele recebe um conjunto de valores de entrada, realiza uma **combinação linear por meio de pesos** (*weights*) e de **um *bias***, e aplica uma **função de ativação** para produzir sua saída.

Matematicamente, o neurônio calcula a entrada líquida:

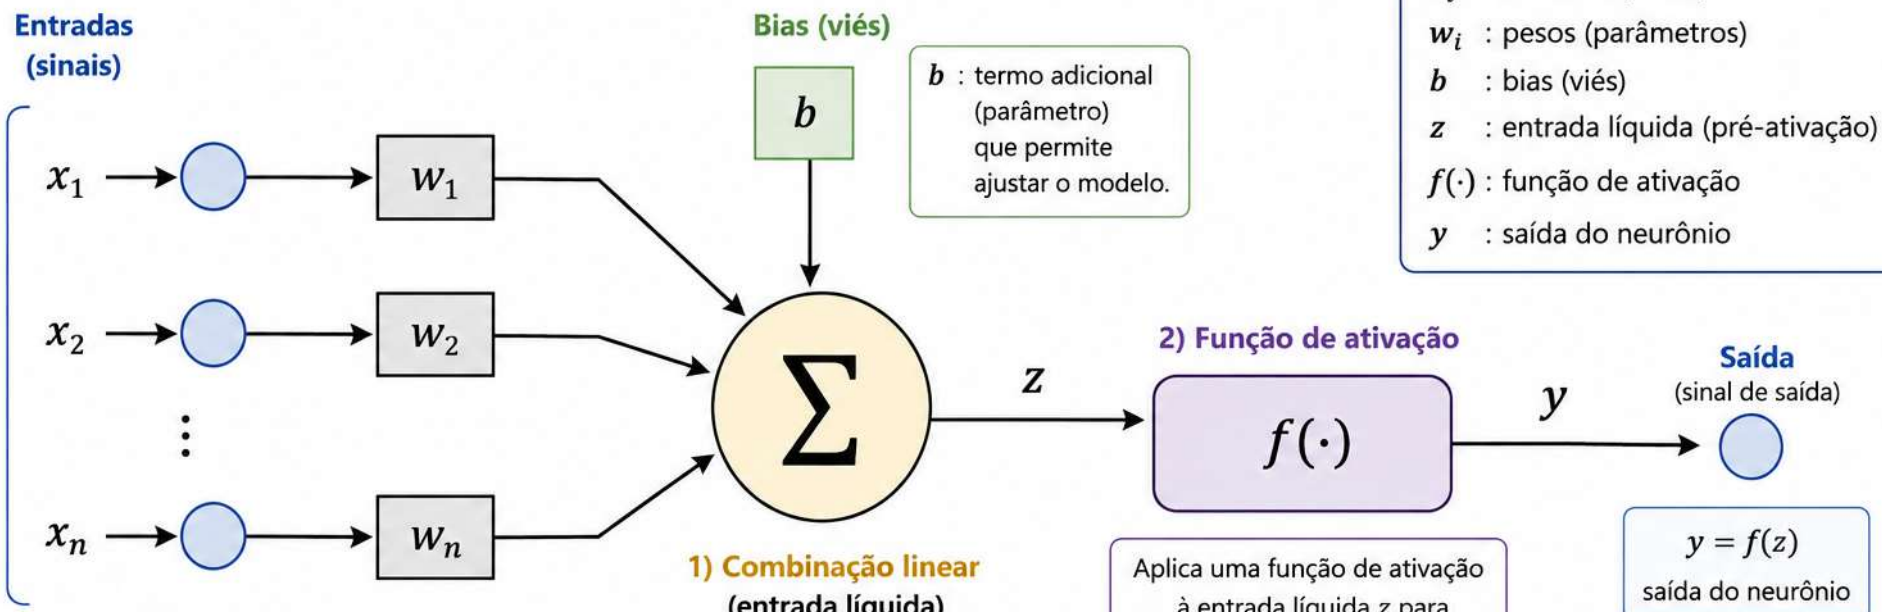
$$z = \sum_{i=1}^{n} w_i x_i + b$$

Em seguida, aplica uma função de ativação:

$$y = f(z)$$

A saída y é então encaminhada para os neurônios da camada seguinte **OU**, caso seja a última camada oculta, utilizada como saída final.

NEURÔNIO ARTIFICIAL



Legenda

- x_i : entradas (sinais)
- w_i : pesos (parâmetros)
- b : bias (viés)
- z : entrada líquida (pré-ativação)
- $f(\cdot)$: função de ativação
- y : saída do neurônio

b : termo adicional (parâmetro) que permite ajustar o modelo.

x_i : i-ésima entrada (sinal)

Pesos (parâmetros)

w_i : peso associado à entrada x_i

1) Combinação linear (entrada líquida)

$$z = \sum_{i=1}^{n} w_i x_i + b$$

z : entrada líquida (*net input*) ou pré-ativação

Aplica uma função de ativação à entrada líquida z para produzir a saída do neurônio.

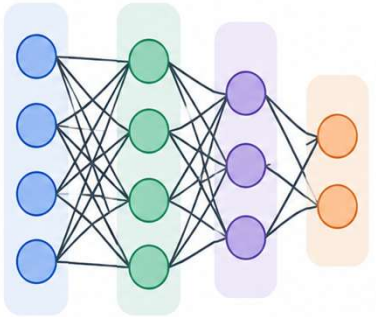
$y = f(z)$
saída do neurônio

Como funciona:

1. Cada entrada x_i é multiplicada pelo seu peso w_i.
2. Os valores ponderados são somados e o bias b é adicionado, produzindo z.
3. A função de ativação $f(\cdot)$ transforma z na saída y.
4. A saída y é enviada para os neurônios da próxima camada ou usada como saída final da rede.

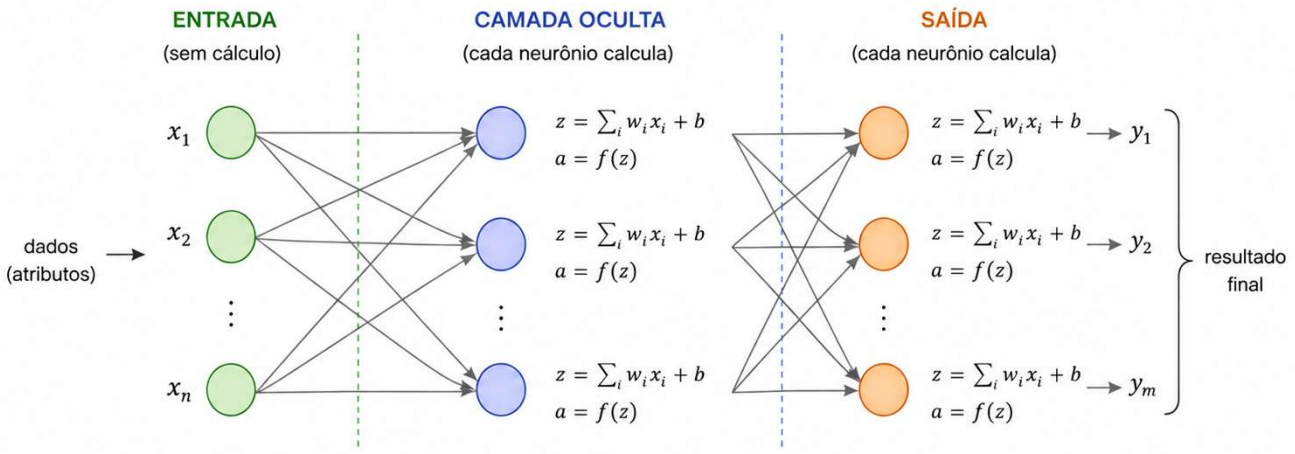
Observação histórica: Em modelos inspirados no neurônio biológico, o valor z já foi chamado de "potencial de ativação". Hoje, os termos mais comuns são entrada líquida, pré-ativação ou simplesmente z.

AS CAMADAS



Redes neurais são arquiteturas de **aprendizagem de máquina** compostas por **neurônios artificiais organizados em camadas,** capazes de aprender representações e padrões a partir dos dados.

Em uma rede *feedforward* convencional, distinguimos três tipos de camadas: **Entrada (Input),** uma ou mais **Camadas Ocultas (Hidden)** e **Saída (Output).**



ENTRADA

- Recebe os dados.
- Não faz cálculo.
- Não possui pesos nem *bias*.

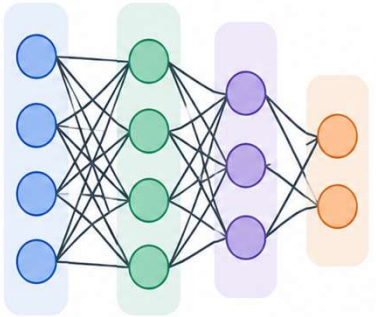
CAMADAS OCULTAS

- Cada neurônio calcula $z = \sum_i w_i x_i + b$.
- Aplica função de ativação: $a = f(z)$.
- Possui pesos (w) e *bias* (b).

SAÍDA

- Cada neurônio calcula $z = \sum_i w_i x_i + b$.
- Aplica (ou não) função de ativação: $a = f(z)$.
- Possui pesos (w) e *bias* (b).

A CAMADA DE ENTRADA



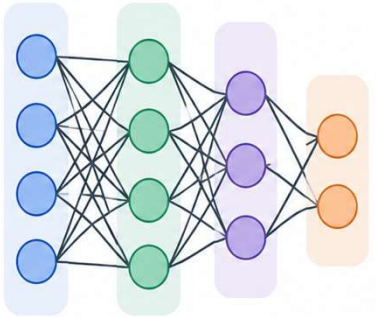
A camada de **Entrada** (*input layers*) recebe os dados de entrada (atributos), representados de **forma numérica** (dados tabulares, pixels de uma imagem etc.).

Em uma MLP tradicional (*), a camada de entrada apenas recebe os dados e os encaminha para a primeira camada oculta. Ela **não realiza processamento matemático** (não possui pesos, bias ou função de ativação).

Por esse motivo, alguns autores **não contabilizam a camada de entrada** ao medir a **profundidade** (*depth*) da rede neural.

* Em arquiteturas mais avançadas, a camada de entrada pode ser seguida por transformações específicas, realizadas por outras camadas, como uma camada de *embedding* em problemas de PLN.

AS CAMADAS OCULTAS



Nas camadas **Ocultas** (*hidden layers*), cada neurônio recebe as saídas da camada anterior, calcula uma combinação linear utilizando **pesos** e **bias** ($z = \sum_{i=1}^{n} w_i x_i + b$) e aplica uma **função de ativação** para produzir sua saída.

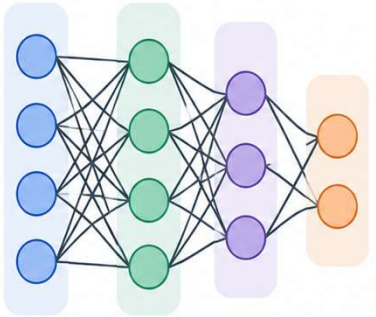
A **quantidade de camadas ocultas** e o **número de neurônios em cada camada** são **hiperparâmetros** definidos durante o projeto da rede.

Não existe uma regra universal para definir a quantidade de neurônios. Algumas **heurísticas** podem ser utilizadas como ponto de partida, como considerar valores próximos à quantidade de nós da camada de entrada ou potências de 2 (16, 32, 64, 128, 256).

As camadas ocultas quase **sempre utilizam funções de ativação**, que introduzem **não linearidade** e permitem que a rede aprenda **representações e relações complexas** a partir dos dados.

Sem funções de ativação nas camadas ocultas, sucessivas transformações lineares equivalem a uma única transformação linear, **limitando a capacidade da rede de modelar relações complexas.**

A CAMADA DE SAÍDA



Na camada de **Saída** (*output layer*) os neurônios também calculam uma combinação linear utilizando **pesos** e **bias** ($z = \sum_{i=1}^{n} w_i x_i + b$). Ou seja, ela **também tem pesos e bias aprendidos durante o treinamento**.

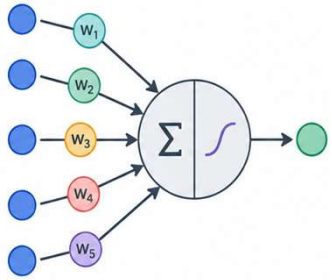
Quando aplicável, a camada de saída também usa **funções de ativação** para o processamento na camada de saída transforma as **representações internas da rede na resposta final do modelo**, adequada ao problema.

A **função de ativação** dependem do tipo de problema, como regressão (identidade), classificação binária (sigmoide) ou multiclasse (softmax).

Em arquiteturas tradicionais*, a **camada de saída é única**, embora possa conter **um ou vários neurônios** também conforme a tarefa.

* Em arquiteturas mais avançadas, a rede pode possuir **múltiplas cabeças de saída (*multiple output heads*)**, geralmente compartilhando uma estrutura comum (*backbone*).

NEURÔNIO ARTIFICIAL



Entradas (x) – Conjunto de valores fornecidos ao neurônio, representando os atributos ou características utilizados no processamento.

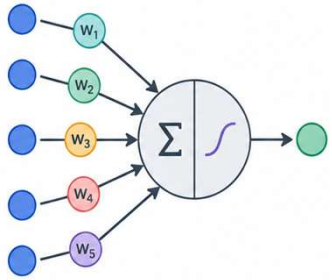
Pesos (w) – Parâmetros aprendidos durante o treinamento que determinam a influência de cada entrada na saída do neurônio.

Bias (b) – Termo adicional aprendido durante o treinamento que ajusta a combinação linear, proporcionando maior flexibilidade ao modelo.

Entrada Líquida ou Pré-Ativação (z) – Resultado da combinação linear entre os valores recebidos da camada anterior, seus respectivos pesos e o *bias*.

$$z = \sum_{i=1}^{n} w_i x_i + b = w_1 x_1 + w_2 x_2 + w_3 x_3 + \cdots + w_n x_n + b$$

NEURÔNIO ARTIFICIAL



Função de Ativação (f) – Função matemática aplicada à entrada líquida (z) para produzir a saída do neurônio.

- É aplicada sobre a entrada líquida (z).
- Introduz **não linearidade** no modelo, permitindo representar relações complexas entre as variáveis.
- O tipo de função de ativação depende da camada e do problema que se deseja resolver.

Saída (y) **ou Ativação** (a) – Saída produzida pelo neurônio a partir da entrada líquida (z), após a aplicação da função de ativação, quando utilizada.

- Nas camadas ocultas, constitui uma representação intermediária enviada à próxima camada; **na camada de saída**, corresponde à **resposta produzida pelo modelo**.

$$a = f(z)$$

Neurônio Artificial aplicado a dados tabulares

1 Dados tabulares

	idade	renda	score	...	alvo (y)
1	25	3000	650	...	0
2	40	8000	700	...	1
3	35	5000	620	...	0
⋮	⋮	⋮	⋮	⋮	⋮
n	28	4500	680	...	1

Cada linha = uma instância (exemplo)
Cada coluna (exceto alvo) = uma característica

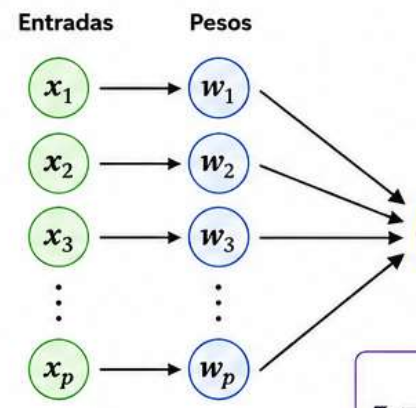
2 Após transformações / padronização

x_1	x_2	x_3	...	x_p	y
−0,45	−1,10	0,20	...	0,35	0
0,85	1,05	1,10	...	−0,15	1
0,30	−0,10	−0,30	...	0,60	0
⋮	⋮	⋮	⋮	⋮	⋮
−0,20	−0,60	0,40	...	0,10	1

Cada linha vira um vetor de **entrada**

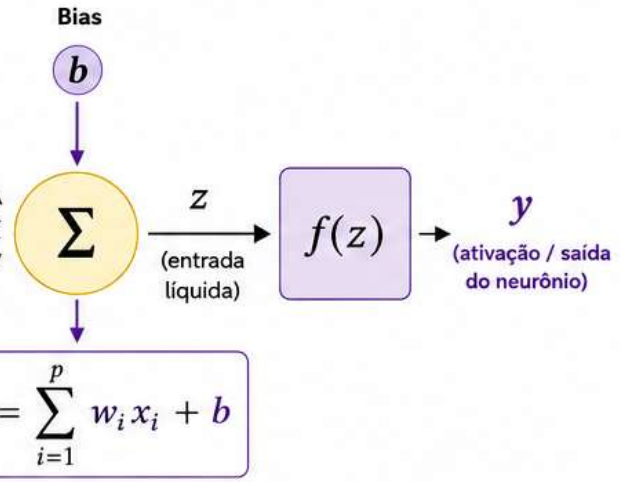
$$x = [x_1, x_2, \ldots, x_p]$$

3 Entradas do neurônio (uma instância)



Cada característica x_i é multiplicada pelo seu peso w_i

4 Entrada líquida (pré-ativação)



$$z = \sum_{i=1}^{p} w_i x_i + b$$

Soma de todos os produtos mais o *bias* (termo de ajuste)

A função de ativação f transforma z na **saída** y

5 Saída: o que queremos prever

y é a previsão gerada pelo neurônio.

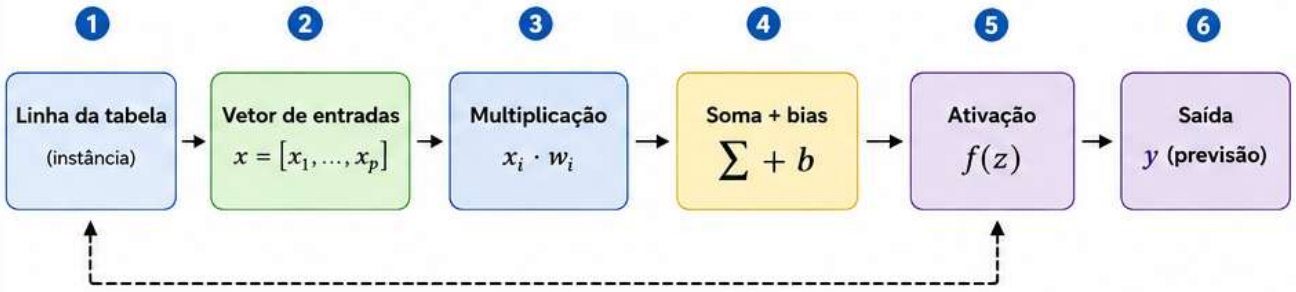
Comparada com o alvo (y real) para calcular o **erro** e **ajustar** os pesos e o *bias*.

$\hat{y}$		y (real)
0,12		0
0,87		1
0,23	Comparação (erro/loss)	0
⋮		⋮
0,75		0

Onde cada elemento atua:

- Pesos (w_i): aprendem a importância de cada característica.
- Bias (b): desloca a função, permitindo ajustar o ponto de decisão.
- Função de ativação (f): introduz não linearidade e define o tipo de saída.

Resumo do fluxo de uma instância (uma linha de dados)



Ajuste dos pesos $(w_1, \ldots, w_p)$ e do *bias* (b) durante o treinamento para reduzir o erro em todas as instâncias