Aprendizagem de Máquina II

Situação Problema Redes Neurais Recorrentes e LSTM

Prof. Luis Claudio

(Bônus 1.0 na Nota T02)

Data: 14 / 10 / 2026	**Duração: 90 minutos**
Trabalho presencial em grupo	**Integrantes: 2 a 6 alunos**

Integrantes

1. _____

2. _____

3. _____

4. _____

5. _____

6. _____

Orientações

- Registre somente os nomes dos participantes presentes em sala.
- Leia o cenário antes de responder (as respostas devem relacionar os conceitos às evidências do cenário).
- Apresente os cálculos utilizados. Respostas sem justificativa não serão consideradas completas.
- O objetivo não é programar o modelo, mas analisar o problema e tomar decisões arquiteturais.

Projeto EscutaCliente

A rede varejista CompraCerta recebe aproximadamente 30 mil mensagens de clientes por mês. Atualmente, uma equipe lê cada mensagem e a encaminha para uma entre três áreas: Entrega, Cobrança ou Cancelamento. Para reduzir o tempo de atendimento, a empresa iniciou o projeto EscutaCliente, cujo objetivo é classificar automaticamente cada mensagem e encaminhá-la à área correta.

Cada mensagem deve receber uma única classificação, correspondente à área responsável por solucionar a solicitação principal do cliente. Um encaminhamento incorreto aumenta o tempo de atendimento, pois a mensagem precisa retornar à fila e ser analisada novamente. Portanto, a empresa procura melhorar a qualidade da classificação sem tornar o processamento excessivamente caro ou demorado.

O primeiro modelo utilizado foi uma MLP alimentada por vetores TF-IDF. O modelo apresentou bom desempenho geral, mas confundiu mensagens formadas por palavras semelhantes em ordens diferentes. Por exemplo, a mensagem “não quero cancelar a compra; quero cancelar apenas a cobrança duplicada” deve ser encaminhada para Cobrança. Já “a cobrança foi corrigida, mas ainda quero cancelar a compra” deve ser encaminhada para Cancelamento.

As mensagens podem mencionar diferentes acontecimentos antes de apresentar a solicitação principal. Em alguns textos, uma informação localizada no início modifica o significado de outra apresentada muito depois. A equipe concluiu que considerar apenas a presença das palavras não era suficiente: a ordem dos elementos e o contexto construído ao longo do texto deveriam ser preservados.

Após o pré-processamento, cada mensagem passou a ser representada por uma sequência de 40 vetores. Cada vetor possui 16 atributos e representa um elemento da sequência. Durante o treinamento, são processadas 32 mensagens por lote. Portanto, a entrada de um lote possui formato (N \times T \times d = 32 \times 40 \times 16).

Como primeira alternativa, a equipe criou uma RNN simples. A primeira camada recorrente possui 8 neurônios e envia a sequência de estados ocultos para uma segunda camada recorrente com 12 neurônios. O último estado oculto da segunda camada é enviado para uma camada densa com 3 neurônios e ativação *softmax*. Os parâmetros recorrentes são reutilizados em todos os passos da sequência.

Nos testes, a RNN simples classificou adequadamente muitas mensagens curtas. Entretanto, seu desempenho caiu nos textos em que uma informação apresentada no início precisava continuar influenciando a interpretação de trechos muito posteriores. A equipe suspeitou que, durante o treinamento, os gradientes que atravessavam muitos passos temporais se tornavam pequenos, reduzindo a capacidade de aprender dependências mais longas.

Uma cientista de dados propôs substituir as duas camadas recorrentes simples por camadas LSTM com as mesmas quantidades de neurônios. Ela explicou que a LSTM mantém o estado oculto (h_t) e também o estado da célula (c_t) ao longo dos passos. Além disso, utiliza a porta de esquecimento, a porta de entrada, a informação candidata e a porta de saída. Cada um desses quatro cálculos possui seus próprios pesos de entrada, pesos recorrentes e biases.

Para que a comparação fosse adequada, a equipe decidiu utilizar os mesmos dados de treinamento e validação e manter inicialmente as mesmas condições de treinamento. Dessa forma, as diferenças observadas poderiam ser relacionadas principalmente à arquitetura utilizada. A decisão final deveria considerar tanto a capacidade de generalização quanto o custo computacional dos modelos.

O gerente questionou o custo da mudança. Ele afirmou que, como cada mensagem possui 40 passos, a rede teria de aprender 40 conjuntos diferentes de pesos e que dobrar o limite para 80 passos duplicaria a quantidade de parâmetros. A equipe precisa avaliar essa afirmação, comparar o custo da RNN simples com o da LSTM e recomendar uma arquitetura que equilibre desempenho e complexidade.

Durante os primeiros experimentos, a perda de treinamento continuou diminuindo, mas a perda de validação começou a aumentar após algumas épocas. Por isso, além da arquitetura, o grupo também deverá considerar decisões de treinamento e alguma forma de regularização.

Dados Técnicos Fornecidos

Elemento	RNN simples	Alternativa LSTM
Entrada	T = 40 e d = 16	T = 40 e d = 16
1ª camada recorrente	8 neurônios	8 neurônios LSTM
2ª camada recorrente	12 neurônios	12 neurônios LSTM
Saída	Dense com 3 neurônios e softmax	Dense com 3 neurônios e softmax
Biases	1/neurônio recorrente	1/ neurônio em cada um dos 4 cálculos

Questões

1) Explique por que a representação de cada mensagem como uma sequência de vetores é mais adequada ao problema do que representar o documento inteiro por um único vetor TF-IDF. Utilize as duas mensagens apresentadas no caso para justificar.

2) A entrada de um lote possui formato 32 × 40 × 16. Explique o significado de cada dimensão e indique exatamente o que a primeira camada recorrente recebe em um único passo temporal.

3) Na primeira camada da RNN simples, explique como o vetor de estado oculto é formado pelos 8 neurônios e como esse vetor participa do processamento do passo seguinte. Por que essa camada possui 8 por 8 pesos recorrentes, e não apenas 8?

4) Calcule, para a RNN simples, a quantidade de pesos de entrada, pesos recorrentes e biases da primeira camada, da segunda camada e da camada densa. Em seguida, determine o total de parâmetros treináveis da rede.

5) Explique por que a RNN simples pode apresentar dificuldade nas mensagens em que informações distantes precisam ser relacionadas. Relacione o problema ao vanishing gradient e justifique por que uma LSTM pode ser mais adequada.

6) Explique a diferença entre o estado oculto h e o estado da célula c. Depois, descreva a função da porta de esquecimento, da porta de entrada, da informação candidata e da porta de saída. Deixe clara a diferença entre propor uma informação candidata e permitir que ela seja armazenada.

7) Mantendo 8 neurônios na primeira camada LSTM e 12 na segunda, calcule a quantidade de pesos de entrada, pesos recorrentes e biases das duas camadas LSTM e da camada densa. Determine o total de parâmetros e compare-o com o total da RNN simples.

8) Avalie a afirmação do gerente de que existem conjuntos diferentes de pesos para cada passo. Se o limite das mensagens passar de 40 para 80 passos, a quantidade de parâmetros mudará? Indique também o que poderá aumentar, mesmo que a quantidade de parâmetros permaneça igual.

9) Apresente a recomendação final do grupo para o projeto EscutaCliente. Indique a arquitetura escolhida, justifique a decisão com base no comportamento observado, proponha decisões para pelo menos três hiperparâmetros de treinamento e inclua uma técnica de regularização adequada ao aumento da perda de validação.